

La recherche reproductible en science computationnelle

R. D. Peng (2011). *Science*, 334(6060), 1226-1227.

Resume

Roger Peng soutient que l'essor de la science computationnelle a multiplie les decouvertes mais a aussi revele les limites de notre capacite a evaluer les resultats publies. La replication (refaire l'etude avec des donnees collectees independamment) reste l'etalon-or, mais elle est souvent impossible : les grands ensembles de donnees comme le Sloan Digital Sky Survey ou les grandes cohortes en epidemiologie environnementale sont trop couteux ou trop longs a reproduire. La **reproductibilite** - rendre disponibles les donnees et le code utilises pour l'analyse - est proposee comme un standard minimal acceptable lorsqu'une replication complete n'est pas realisable.

Le spectre de la reproductibilite et les obstacles

Peng decrit la reproductibilite comme un spectre allant de la simple publication (non reproductible) jusqu'au code et aux donnees lies et executables, avec la replication complete comme reference ultime. Le principal obstacle est que le code n'est souvent plus disponible, car les logiciels interactifs ne conservent pas la trace des actions. Il presente la politique de la revue *Biostatistics* (dont il est redacteur associe) : des labels 'D', 'C' et 'R' selon que les donnees, le code, ou la reproductibilite verifiee sont fournis.

Recommandations

Peng insiste sur le fait que la reproductibilite ne garantit pas l'exactitude, mais qu'elle aide a depister les erreurs et a batir sur les resultats. Il propose des etapes progressives : d'abord, publier son code, meme imparfait (cout quasi nul, via GitHub ou SourceForge) ; ensuite, publier une version nettoye du code avec les donnees dans un format durable et non proprietaire ; enfin, creer des depots communs de type 'DataMed Central' et 'CodeMed Central', analogues a PubMed Central. Il conclut qu'instaurer une veritable culture de la reproductibilite exigera du temps et un effort soutenu de la communaute scientifique.